

RELATÓRIO DE ANÁLISE DE PACIENTES COM CÂNCER DE MAMA

1. Introdução

Este relatório tem como objetivo apresentar uma análise exploratória e estatística de um conjunto de dados clínicos de pacientes diagnosticados com câncer de mama, permitindo identificar padrões relevantes relacionados à **sobrevivência, mortalidade e fatores de risco**.

O dataset utilizado contém informações demográficas, clínicas e biológicas dos pacientes, incluindo idade, raça, estado civil, estágio do câncer, tamanho do tumor, status hormonal e tempo de sobrevivência.

A análise foi desenvolvida utilizando **Power BI**, com foco na geração de insights e apoio à tomada de decisão.

2. Visão Geral dos Dados

- Total de pacientes: ~4.000
- Pacientes vivos: ~84,7%
- Pacientes que foram a óbito: ~15,3%
- Taxa geral de sobrevivência: **84,7%**

Perfil dos pacientes:

- Maioria entre **50 e 69 anos**
- Predominância da raça **branca**
- Maior parte dos pacientes **casados**

3. Modelagem de Dados e Métricas

Para possibilitar análises mais precisas, foram criadas medidas e colunas calculadas no Power BI, com o objetivo de transformar os dados brutos em indicadores relevantes.

Entre as principais métricas desenvolvidas, destacam-se:

- **Taxa de Mortalidade:** indicador que representa a proporção de pacientes que foram a óbito em relação ao total analisado.
- **Taxa de Sobrevivência:** percentual de pacientes vivos, permitindo análise geral do cenário.
- **Identificação do Grupo de Maior Risco:** medida utilizada para destacar automaticamente o grupo com maior taxa de mortalidade.

Além disso, foram criadas colunas auxiliares para melhorar a organização e interpretação dos dados, como:

- Faixa etária dos pacientes
- Tradução e padronização de variáveis categóricas
- Agrupamentos para facilitar a análise visual

Essas transformações foram fundamentais para viabilizar análises comparativas e geração de insights ao longo do dashboard.

4. Pré-processamento dos Dados

Antes da análise e modelagem, foi realizada uma etapa de pré-processamento com o objetivo de garantir a qualidade, consistência e confiabilidade dos dados.

As principais estratégias adotadas foram:

Tratamento de valores ausentes

Foram identificados campos com valores nulos ou inconsistentes. Dependendo do caso, os dados foram:

- Removidos (quando irrelevantes ou em pequena quantidade)
- Substituídos por média ou moda (em variáveis numéricas e categóricas)

Padronização de variáveis categóricas

Algumas variáveis apresentavam inconsistência de idioma ou nomenclatura. Foi realizada a padronização para melhorar a interpretação e análise, como:

- Tradução de categorias (ex: “Married” → “Casado”)
- Agrupamento de categorias semelhantes

Criação de novas variáveis

Foram criadas colunas auxiliares para enriquecer a análise:

- Faixa etária (ex: 30–39, 40–49, etc.)
- Classificação de diagnóstico (quando necessário)
- Agrupamentos de risco

Remoção de outliers

Valores extremos foram analisados e tratados quando identificados como inconsistentes ou erros de registro, evitando distorções nos resultados.

Normalização (quando aplicável)

Algumas variáveis numéricas foram ajustadas para facilitar comparações e análises visuais.

Integração de dados (quando aplicável)

Para análises mais completas, os dados foram organizados em um modelo estruturado, permitindo cruzamento entre variáveis clínicas e demográficas.

5. Análise Demográfica

Raça

- Pacientes brancos representam a maior parte da amostra
- Também apresentam maior taxa de mortalidade (~12%)
- Outras raças possuem menor representatividade e menor taxa de óbito

Insight:

A concentração de casos em pacientes brancos pode impactar diretamente os resultados gerais.

Faixa Etária

- Maior incidência entre:
 - 50 a 59 anos
 - 60 anos ou mais

Insight:

O risco aumenta com a idade, reforçando a importância do diagnóstico **precoce**.

6. Impacto do Estado Civil na Mortalidade

Resultados principais:

- Separadas → **33,3% (maior mortalidade)**
- Viúvas → 20,9%
- Divorciadas → 18,5%
- Casadas → **14,2% (menor mortalidade)**

Insight:

Pacientes **sem apoio conjugal direto** apresentam maior taxa de mortalidade.

Isso pode indicar impacto de fatores como:

- suporte emocional
- adesão ao tratamento
- acompanhamento médico

7. Análise por Estágio do Câncer

Mortalidade por estágio:

- IIIA e IIIC → maiores taxas de mortalidade
- IIA → menor taxa

Sobrevivência:

- Estágios iniciais apresentam maior média de sobrevivência (~70+ meses)
- Estágios avançados apresentam queda significativa

Tamanho do tumor:

- Tumores maiores estão associados a estágios mais avançados

Insight forte:

Existe uma relação clara entre:

- ➡ estágio avançado
- ➡ maior tumor
- ➡ menor sobrevivência

8. Análise Hormonal

Estrogênio

- Positivo → ~12,6% mortalidade
- Negativo → ~2,7%

Progesterona

- Positivo → ~10,2% mortalidade
- Negativo → ~5%

Distribuição:

- Maioria dos pacientes é **positiva** para ambos os hormônios

Insight:

- Pacientes com **receptores hormonais positivos** apresentam maior mortalidade neste dataset
- Estrogênio apresenta impacto mais forte que progesterona

Isso pode indicar:

- maior agressividade em determinados casos
- ou características específicas da amostra analisada

9. Relação entre Tumor e Sobrevivência

O gráfico de dispersão mostrou que:

- Tumores maiores tendem a ter menor tempo de sobrevivência
- Pacientes que foram a óbito concentram-se em:
 - menores meses de sobrevivência
 - maior variação de tamanho tumoral

Insight:

Existe correlação visual entre:

- ➡ aumento do tumor
- ➡ redução da sobrevivência

10. Principais Insights do Projeto

- ✓ A maioria dos pacientes sobrevive (84,7%)
- ✓ Estado civil influencia significativamente a mortalidade
- ✓ Estágios mais avançados aumentam drasticamente o risco
- ✓ Tumores maiores → menor sobrevivência
- ✓ Status hormonal impacta o prognóstico
- ✓ Idade é um fator crítico

11. Modelagem e Abordagem de Machine Learning

O problema abordado neste projeto é caracterizado como um problema de **classificação**, cujo objetivo é identificar padrões associados à mortalidade e sobrevivência de pacientes com câncer de mama.

Embora o foco principal tenha sido a análise exploratória no Power BI, foram considerados modelos de Machine Learning adequados para evolução do projeto.

Regressão Logística

Modelo utilizado para classificação binária (óbito vs sobrevivência).

Justificativa:

- Alta interpretabilidade
- Muito utilizado na área médica
- Permite entender o impacto das variáveis

Árvore de Decisão

Modelo baseado em regras para segmentação dos dados.

Justificativa:

- Fácil visualização
- Identificação de padrões entre variáveis
- Explicabilidade para tomada de decisão

Random Forest

Conjunto de múltiplas árvores de decisão.

Justificativa:

- Maior precisão
- Redução de overfitting
- Capacidade de capturar relações complexas

Considerações

Os modelos não foram implementados diretamente neste projeto, sendo recomendados como evolução futura, com uso de ferramentas como Python e Scikit-learn para construção de modelos preditivos.

12. Conclusão

A análise evidencia que o câncer de mama não depende de um único fator, mas sim de uma combinação de variáveis clínicas e sociais.

Os principais fatores associados ao aumento da mortalidade são:

- Estágio avançado do câncer
- Maior tamanho tumoral
- Status hormonal
- Estado civil (fator social relevante)

Esses achados reforçam a importância de:

- diagnóstico precoce
- acompanhamento contínuo
- suporte ao paciente

13. Considerações Finais

Este projeto demonstra a aplicação prática de:

- Análise exploratória de dados
- Modelagem em Power BI
- Criação de KPIs e métricas
- Storytelling com dados